

Extraction automatique de jugements judiciaires Word vers JSON structuré

Pipeline Python stabilisé : `extract_judgments_to_json_v16.py`

Mohamed Soueidatt

Faculté des Sciences et Technologies
Université de Nouakchott

Module : Python pour le Calcul Scientifique (PCS)
Professeur : Dr. El Benany Med Mahmoud

28 mai 2026

Plan de la présentation


- 1 Contexte du projet et problème traité
- 2 Pipeline Python d'extraction
- 3 Standardisation JSON des jugements
- 4 Stabilisation du script jusqu'à la version V16
- 5 Résultats obtenus et préparation de l'annotation

Contexte : des jugements Word vers des données exploitables

Constat de départ

Les jugements judiciaires sont disponibles sous forme de fichiers Word, mais ils ne sont pas directement exploitables par des modèles d'IA.

- documents hétérogènes ;
- langue arabe juridique ;
- titres et sections non standardisés ;
- noms de personnes complexes ;
- besoin de préparation avant anonymisation.



Objectif du projet

Objectif principal

Construire un pipeline Python capable de convertir automatiquement un dossier de jugements Word en fichiers JSON standardisés.


Entrées

- Fichiers Word .docx ;
- fichiers .doc convertibles ;
- corpus brut de jugements.

Sorties


- JSON par jugement ;
- fichier JSONL global ;
- tâches Label Studio ;
- rapport CSV d'extraction.

Architecture générale du pipeline



Le traitement est automatisé au niveau du dossier complet, avec journalisation des erreurs et des avertissements.

Schéma JSON standardisé



Contenu principal :

- nom du fichier source ;
- numéro de dossier / jugement ;
- dates ;
- accusation ;
- participants ;
- sections ;
- texte brut et nettoyé ;
- erreurs et avertissements.

Détection flexible des sections

Principe

Le début d'une section marque la fin de la section précédente. Le script ne dépend pas d'un ordre unique.

Sections détectées

- facts : الوقائع
- procedures : الإجراءات
- facts_procedures : الوقائع والإجراءات
- court : المحكمة
- reasons : الأسباب / الحثيات
- legal_basis : لهذه الأسباب
- operative_part : منطوق الحكم

Variantes prises en charge

- absence de numérotation ;
- titre collé au texte ;
- fautes fréquentes : الإجراءات ;
- ordre inversé : procédures puis faits ;
- titres synonymes : أسباب الحكم ;
- fusion : الوقائع والإجراءات.

Exemples de cas réels gérés par la version V16

Titre collé au texte

وبعد التأمل طبقا للقانون. رابعا: منطوق الحكم

Section fusionnée

أولا: الوقائع والإجراءات

Variante orthographique

أسباب والحديثيات

Faux positif évité


فقدم ملخصا عن الوقائع وطالب بإدانة المتهمين

ici, الوقائع est un mot dans la phrase, pas un titre.

Liste de personnes

المتهم : 1- محمد اسويدات 2 بناني محمد محمود 3 أحمد السالك المختار

Stabilisation progressive : de V1 à V16



Résultat de l'itération

Chaque version a été ajustée à partir de cas réels rencontrés dans les jugements, jusqu'à obtenir une version stabilisée : `extract_judgments_to_json_v16.py`.

Extraction des participants

Objectif

Construire un index des personnes importantes du jugement : accusés, parties civiles, victimes ou groupes mentionnés.

- prise en charge du singulier et du pluriel ;
- noms multiples sur une seule ligne ;
- listes numérotées ou à puces ;
- conservation du nom brut.

المتهم : 1- محمد اسويدات ... 2 بناني محمد محمود ...

Découpage regex

participants_index

Résultat d'exécution du script

Sorties générées automatiquement

- judgments_master.jsonl : corpus complet;
- extraction_report.csv : rapport qualité;
- dossier json/ : un JSON par document;
- labelstudio_tasks.jsonl : préparation de l'annotation.

```
Done. OK=2048 ERROR=0
JSONL: C:\Jugements_DataSet\all_data_out\judgments_master.jsonl
Report: C:\Jugements_DataSet\all_data_out\extraction_report.csv
Per-doc JSON: C:\Jugements_DataSet\all_data_out\json
Label Studio JSONL: C:\Jugements_DataSet\all_data_out\labelstudio_tasks.jsonl
```


Résultats quantitatifs obtenus

2048
fichiers analysés

2048
fichiers traités avec succès

0
erreur d'exécution

3778
mentions de personnes comptées



Contrôle qualité et sélection du corpus d'annotation

Contrôle qualité

Le rapport d'extraction permet de vérifier automatiquement :

- fichiers traités et erreurs ;
- champs manquants ;
- sections détectées ;
- avertissements ;
- documents atypiques.

Sélection pour annotation

Un script secondaire sélectionne les fichiers les plus riches en personnes.

Compter les personnes par JSON



Trier par nombre décroissant




Sélectionner les 300 premiers



Préparer Label Studio

Lien avec la thèse : IA et anonymisation juridique



Position du projet

L'extraction Word vers JSON constitue la première étape technique de la chaîne d'anonymisation et d'exploitation IA des jugements mauritaniens.

Compétences Python mobilisées

- manipulation de fichiers et dossiers ;
- parsing de documents Word ;
- expressions régulières ;
- traitement de texte arabe ;
- génération JSON / JSONL / CSV ;
- gestion d'erreurs ;
- automatisation de pipeline.

Valeur ajoutée

- corpus structuré ;
- extraction reproductible ;
- traçabilité des erreurs ;
- préparation de Label Studio ;
- base solide pour un modèle NER.

Limites et perspectives

Limites actuelles

- documents contenant plusieurs jugements ;
- titres extrêmement atypiques ;
- extraction des participants encore heuristique ;
- absence de validation sémantique profonde.

Perspectives

- annotation NER dans Label Studio ;
- entraînement d'un modèle de reconnaissance d'entités ;
- anonymisation automatique ;
- évaluation du rappel sur les données personnelles ;
- extension du corpus.

Synthèse

Le projet a permis de construire un pipeline Python complet pour transformer automatiquement des jugements judiciaires Word hétérogènes en données JSON structurées.

- Version stabilisée : `extract_judgments_to_json_v16.py`
- 2048 fichiers traités avec succès
- préparation directe de l'annotation et de l'anonymisation
- base technique essentielle pour l'IA juridique appliquée aux jugements mauritaniens

Merci pour votre attention